Федеральное государственное автономное образовательное учреждение
высшего образования
«Самарский национальный исследовательский университет
имени академика С.П. Королёва»

Факультет информатики
Кафедра технической кибернетики

ОТЧЁТ

по лабораторной работе №1
по дисциплине «Анализ социальных сетей»

Сбор данных из социальных сетей

Выполнил: студент группы 6231-010402D
Васильев Артём

Проверил: _____

Самара, 2026

Содержание

Введение 3
1. Исходные данные и средства реализации 3
1.1. Источник данных 3
1.2. Выбор способа сбора 3
1.3. Программные средства 3
1.4. Структура программы 4
2. Алгоритм сбора данных 4
2.1. Подготовка границ периода 4
2.2. Постраничная загрузка 4
2.3. Фильтрация по дате 4
2.4. Извлечение полей 5
2.5. Сохранение результата 5
2.6. Запуск 5
3. Результаты 6
3.1. Собранный набор данных 6
3.2. Проверка данных 6
3.3. Активность сообщества 6
3.4. Вовлечённость аудитории 7
3.5. Типы вложений 8
4. Особенности и ограничения 8
5. Выполнение требований задания 9
Заключение 9
Приложение А. Собранные посты 10
Приложение Б. Файлы результатов 12

Введение

Цель работы: научиться работать с открытыми API социальной сети «ВКонтакте» и получать из неё данные для дальнейшей обработки.

Объект сбора — посты сообщества Самарского университета за период с 01.08.2026 по 31.08.2026. Собранный набор из 40 записей затем используется в лабораторной работе №2.

Задачи работы:

- выбрать способ сбора данных и настроить доступ к API;
- получить посты сообщества за заданный период;
- извлечь дату, текст, число лайков, комментариев и репостов, а также другие доступные поля;
- сохранить результат в файл и проверить его полноту и корректность.

1. Исходные данные и средства реализации

1.1. Источник данных

Таблица 1 – Параметры сбора

Параметр	Значение
Сообщество	Самарский университет во «ВКонтакте»
Адрес	https://vk.ru/samara_university
Короткое имя в API	samara_university
Период	01.08.2026 00:00:00 – 31.08.2026 23:59:59 (UTC)
Метод API	`wall.get`
Постов за один запрос	100 (максимум метода)
Форматы результата	CSV и JSON

1.2. Выбор способа сбора

Задание допускает библиотеку `vk_api`, веб-скрейпинг и другие подходы. Выбрана библиотека `vk_api`: API возвращает данные в структурированном виде, включая счётчики лайков, комментариев, репостов и просмотров, поэтому не нужно разбирать HTML-разметку, которая может меняться.

1.3. Программные средства

Работа выполнена на языке Python 3.12 в виртуальном окружении; полный список версий зафиксирован в файле `req.txt`. Основные библиотеки: `vk_api` 11.10.1 (обращение к API) и `python-dotenv` 1.2.3 (загрузка токена). Модули `csv` и `json` входят в стандартную библиотеку.

Токен доступа хранится в файле `lab1/.env` в переменной `API_TOKEN`. Этот файл исключён из git, поэтому токен не попадает в репозиторий. Если токен не найден, конструктор класса вызывает ошибку `ValueError`.

1.4. Структура программы

Решение состоит из одного модуля `lab1/collect_post_from_vk.py` с классом `VKParser`.

Таблица 2 – Методы класса VKParser

Метод	Назначение
`__init__`	загружает токен, задаёт сообщество и границы периода
`get_all_posts`	получает посты, фильтрует их по дате и извлекает поля
`save_to_csv`	сохраняет список постов в CSV
`save_to_json`	сохраняет список постов в JSON

2. Алгоритм сбора данных

2.1. Подготовка границ периода

ВКонтакте хранит время публикации как Unix-время, то есть число секунд с 1 января 1970 года. Поэтому границы периода тоже переводятся в это представление, после чего даты сравниваются как обычные числа:

```
self.start_date = datetime(2026, 8, 1, 0, 0 , 0, tzinfo=timezone.utc)
self.end_date = datetime(2026, 8, 31, 23, 59, 59, tzinfo=timezone.utc)
self.start_timestamp = int(self.start_date.timestamp())
self.end_timestamp = int(self.end_date.timestamp())
```

2.2. Постраничная загрузка

Метод `wall.get` возвращает не более 100 постов за запрос, поэтому стена читается частями. Каждый следующий запрос сдвигает параметр `offset` на 100. Цикл заканчивается, когда стена пуста или найден пост старше начала периода.

```
while True:
    response = vk.wall.get(domain=domain, count=max_posts_by_request, offset=offset)
    items = response.get("items", [])
    if not items:
        break
    ...
    offset += max_posts_by_request
```

2.3. Фильтрация по дате

Посты на стене идут от новых к старым. Это позволяет не просматривать всю стену: как только встретился пост старше начала периода, все последующие тоже будут старше.

Таблица 3 – Обработка поста в зависимости от даты

Условие	Значение	Действие
`post_date > end_ts`	пост новее периода	пропустить, перейти к следующему
`post_date < start_ts`	пост старше периода	завершить сбор
иначе	пост в пределах периода	извлечь поля и сохранить

2.4. Извлечение полей

Ответ API состоит из вложенных словарей, а отдельные поля у поста могут отсутствовать. Чтение через `get` со значением по умолчанию не даёт программе упасть с ошибкой `KeyError`.

Таблица 4 – Сохраняемые поля

Поле	Откуда берётся	Содержимое
`id`	`id`	номер поста на стене
`date`	`date`	дата и время в UTC, строка
`timestamp`	`date`	Unix-время (только в JSON)
`text`	`text`	текст, переносы строк заменены пробелами
`likes`	`likes.count`	число лайков
`comments`	`comments.count`	число комментариев
`reposts`	`reposts.count`	число репостов
`views`	`views.count`	число просмотров
`link`	`owner_id, id`	ссылка на пост
`attachments`	`attachments[].type`	типы вложений через запятую или None

2.5. Сохранение результата

– CSV записывается через `csv.DictWriter` в кодировке `utf-8-sig`: метка BOM нужна, чтобы Excel правильно показал кириллицу. Параметр `extrasaction` отбрасывает поле `timestamp`, которого нет в списке столбцов.

– JSON записывается через `json.dump` с параметром `ensure_ascii=False`, поэтому кириллица остаётся читаемой.

2.6. Запуск

Изначально сбор запускался из `main.py`. Сейчас этот файл вызывает только лабораторные работы №2 и №3, которые читают уже сохранённые данные, поэтому для повторного сбора нужно выполнить из корня проекта следующий код:

```
import vk_api
from lab1.collect_post_from_vk import VKParser

vkParser = VKParser()
vk_session = vk_api.VkApi(token=vkParser.token)
vk = vk_session.get_api()
posts = vkParser.get_all_posts(vk)
vkParser.save_to_csv(posts)
vkParser.save_to_json(posts)
```

3. Результаты

3.1. Собранный набор данных

Таблица 5 – Характеристики набора

Показатель	Значение
Собрано постов	40
Дата самого раннего поста	2026-08-02 08:53:11
Дата самого позднего поста	2026-08-31 17:44:23
Дней с публикациями	21 из 31
Постов без текста	1
Длина текста, символов: средняя / минимальная / максимальная	1091 / 241 / 2683
Столбцов в CSV / полей в JSON	9 / 10

Запись в формате JSON выглядит так (текст сокращён):


```
{
    "id": 41204,
    "date": "2026-08-31 17:44:23",
    "timestamp": 1788198263,
    "text": "У научных коллективов университета много…",
    "likes": 58,
    "comments": 0,
    "reposts": 1,
    "views": 7533,
    "link": "https://vk.com/wall-69812_41204",
    "attachments": "photo, photo, photo"
}
```


3.2. Проверка данных

Полученные файлы проверены отдельно от программы сбора:

– все 40 номеров постов уникальны, дубликатов нет;
– все даты находятся в заданном периоде, порядок строго от новых постов к старым;
– значения id, текста и всех счётчиков в CSV и JSON совпадают;
– у всех постов заполнены счётчик просмотров и ссылка.

3.3. Активность сообщества

В среднем выходило 1,3 поста в день. Больше всего постов опубликовано 28 августа (5), а по дням недели лидирует пятница (11 постов), тогда как на субботу и воскресенье приходится по 2 поста.

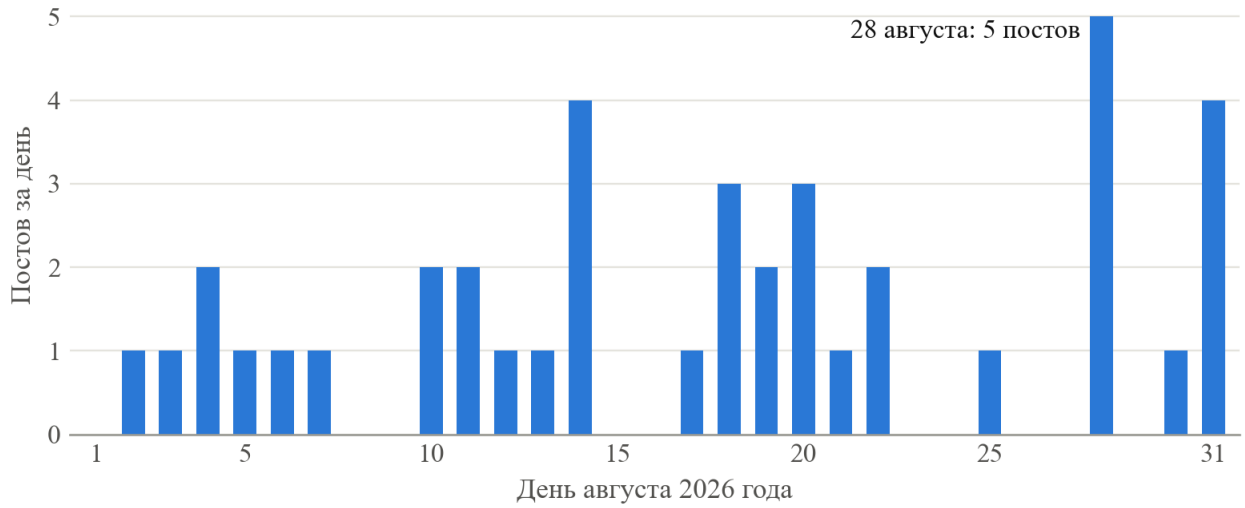


Рисунок 1 – Количество постов по дням августа 2026 года

3.4. Вовлечённость аудитории

Таблица 6 – Счётчики постов

Показатель	Минимум	Медиана	Среднее	Максимум	Сумма
Лайки	9	50	80,7	323	3 227
Комментарии	0	0	0,9	9	36
Репосты	0	7	12,1	81	482
Просмотры	959	7 486	9 687	35 149	387 480

Среднее заметно выше медианы: большинство постов собирает умеренный отклик, а несколько самых популярных сильно поднимают среднее. Комментируют посты редко: 23 из 40 постов не имеют ни одного комментария. Лайки сильно связаны с просмотрами (коэффициент корреляции Пирсона 0,89), но для 40 постов это лишь описательная оценка.

Таблица 7 – Пять постов с наибольшим числом просмотров

Дата	Начало поста	Лайки	Реп.	Просм.
14.08	Магистр Института экономики и управления Андрей Королев стал первым в…	319	42	35 149
28.08	День знаний Самарского университета им. Королёва Первого сентября…	323	81	26 716
20.08	42 студента Самарского университета им. Королёва – стипендиаты…	229	55	22 363
07.08	Портрет первокурсника-2026 Смотрите, кто пришел на бюджет! Сегодня, 7…	157	37	19 646
19.08	19 августа в Самарской области – региональный День особо охраняемых…	90	8	16 429

3.5. Типы вложений

Таблица 8 – Вложения в постах

Тип	Постов с таким вложением	Всего вложений
Фотография (photo)	34	96
Видео (video)	5	5
Подкаст (podcast)	1	1
Без вложений	1	—

Один пост содержит одновременно фотографии и подкаст, поэтому он учтён в двух строках. Сообщество опирается в основном на фотографии: они есть в 34 постах из 40.

4. Особенности и ограничения

Таблица 9 – Выявленные особенности сбора

Особенность	Последствие	Как учтено
Запрос нужно выполнять без VPN	Требование зафиксировано в комментарии в коде; причина не исследовалась	VPN отключается перед запуском
Границы периода заданы в UTC, а время Самары — UTC+4	Посты первых 4 часов 1 августа по местному времени не попадают в период, а посты последних 4 часов 31 августа по UTC относятся по местному времени к 1 сентября	Самый поздний пост вышел в 17:44 UTC, то есть ещё 31 августа. Постов за 1 августа в наборе нет
Сбор останавливается на первом посте старше периода	Старый закреплённый пост, идущий первым, остановил бы сбор сразу: признак закрепления не проверяется	В этом запуске такого не произошло: собрано 40 постов. При повторном сборе проверку стоит добавить
Пост 41104 без текста и вложений	Содержание по сохранённым полям определить нельзя; возможно, это репост, но исходная запись не сохраняется	Запись оставлена в файле, в работе №2 она отбрасывается
Счётчики меняются со временем	Значения относятся к моменту сбора; файлы добавлены в репозиторий 30.09.2026	Новый запуск может дать другие значения
При пустом результате `save_to_csv` не завершается	Будет создан файл только с заголовком, тогда как `save_to_json` файл не создаёт	На результат не повлияло: данные есть. Стоит добавить `return`

5. Выполнение требований задания

Таблица 10 – Сопоставление с результатом из задания

Требование	Где выполнено
Файл с данными о постах	CSV и JSON в папке `lab1/results`
Сообщество и период	Самарский университет, 01.08.2026 – 31.08.2026
Дата публикации	`date` (и `timestamp` в JSON)
Текст	`text`
Количество лайков, комментариев, репостов	`likes`, `comments`, `reposts`
Другие доступные поля	`id`, `views`, `link`, `attachments`

Заключение

В ходе работы с помощью библиотеки `vk_api` и метода `wall.get` собраны 40 постов сообщества Самарского университета за август 2026 года. Результат сохранён в форматах CSV и JSON; файлы совпадают по содержанию, дубликатов и дат вне периода в них нет.

Посты суммарно набрали 387 480 просмотров, 3 227 лайков и 482 репоста; комментариев мало — 36. Набор используется для текстового анализа в лабораторной работе №2.

Основная доработка на будущее — учитывать закреплённые посты при остановке сбора и согласовать границы периода с местным временем.

Приложение А. Собранные посты

В таблице приведено начало каждого поста без эмодзи и ссылок. Полные тексты находятся в файле `lab1/results/samara_university_august_2026.csv`.

Таблица 11 – Посты в порядке от новых к старым

№	Дата	Начало поста	Лайки	Комм.	Реп.	Просм.
1	31.08	"У научных коллективов университета много значимых…	58	0	1	7 533
2	31.08	От Центра управления полётами до скалодрома: участники…	47	0	10	6 853
3	31.08	Мнение эксперта: «Политическое лобби нашему авиапрому нужно и…	32	1	2	6 685
4	31.08	Чем может обернуться заманчивое предложение о легких деньгах?…	16	0	4	3 644
5	30.08	Один телефонный звонок может стать началом опасной цепочки…	29	0	5	5 539
6	28.08	«Самая ценная реликвия, которую мне передали родители и…	137	3	27	14 184
7	28.08	Приёмная кампания в Самарском национальном исследовательском…	190	1	9	15 987
8	28.08	День знаний Самарского университета им. Королёва Первого…	323	1	81	26 716
9	28.08	Футбольный дебют – и уже победа! В Самаре прошёл традиционный…	53	0	4	5 588
10	28.08	Подготовка инженеров для космоса сегодня невозможна без…	36	0	0	4 606
11	25.08	Студенты предложили свои варианты привлечения внимания…	68	0	11	9 922
12	22.08	Александр Борисович Фетисов: «Чтобы решить задачу, в неё…	78	0	4	12 499
13	22.08	Сегодня – День Государственного флага России…	42	1	1	7 233
14	21.08	Николай Бестужев – кто он? По мнению доктора филологических…	39	1	4	7 518
15	20.08	42 студента Самарского университета им. Королёва…	229	4	55	22 363
16	20.08	История Самарской области – это не только события и даты. Это…	39	0	1	6 599
17	20.08	Продолжается прием заявок на участие в «Зимнем университете»…	38	1	3	7 454
18	19.08	19 августа в Самарской области – региональный День особо…	90	0	8	16 429
19	19.08	Архитектура Самары отражает богатое культурное и духовное…	41	0	9	5 608

№	Дата	Начало поста	Лайки	Комм.	Реп.	Просм.
20	18.08	Наш выпускник Кирилл Галанов назначен общественным помощником…	36	1	9	4 635
21	18.08	Координационный центр в рамках рубрики «Взгляд психолога»…	30	0	2	4 288
22	18.08	Дмитрий Фомичев, студент Института авиационной и…	114	0	10	9 026
23	17.08	Два технических клуба, 8 команд, 5 призовых мест!…	85	0	10	7 131
24	14.08	Семь студентов и аспирантов университета стали победителями…	96	3	9	13 606
25	14.08	Координационный центр расспросил студенческих лидеров из…	32	0	0	4 964
26	14.08	Магистр Института экономики и управления Андрей Королев стал…	319	9	42	35 149
27	14.08	Смотрите, кто пришел! Приемная кампания движется к финалу, и…	84	1	25	959
28	13.08	Добрый день, уважаемые слушатели! Сегодня мы представляем вам…	54	0	18	8 354
29	12.08	Приветствуем вас, дорогие первокурсники! Мы искренне рады…	17	0	14	6 195
30	11.08	В новом выпуске программы «Эксперименты Платоновой» ведущая…	15	0	0	5 491
31	11.08	В Самарской области объявили победителей ежегодного конкурса…	38	2	6	7 910
32	10.08	нет текста	9	0	3	4 644
33	10.08	Это лето выдалось на редкость богатым на грозы, да еще и в…	17	0	1	4 639
34	07.08	Портрет первокурсника-2026 Смотрите, кто пришел на бюджет!…	157	3	37	19 646
35	06.08	В музеи, зоопарки и ботанические сады мы привыкли ходить…	45	1	4	10 290
36	05.08	Самарская делегация приняла участие в работе международной…	63	0	4	10 025
37	04.08	Ольга Есипова удостоена Благодарности губернатора Самарской…	282	0	18	15 657
38	04.08	Завтра, 5 августа, в 15:00 закрывается окно возможности…	21	0	5	5 754
39	03.08	Выпускники химических направлений университета вошли в число…	68	2	18	8 479
40	02.08	Внимание! Открытие Ботанического сада Самарского университета…	60	1	8	7 678

Приложение Б. Файлы результатов

Таблица 12 – Файлы в папке lab1/results

Файл	Содержимое
`samara_university_august_2026.csv`	посты, 9 столбцов, кодировка UTF-8 с BOM
`samara_university_august_2026.json`	те же посты и поле `timestamp`
`LR1_report.pdf`	отчёт по лабораторной работе