Федеральное государственное автономное образовательное учреждение
высшего образования
«Самарский национальный исследовательский университет
имени академика С.П. Королёва»

Факультет информатики
Кафедра технической кибернетики

ОТЧЁТ

по лабораторной работе №2
по дисциплине «Анализ социальных сетей»

Предобработка и классификация данных из социальных сетей

Выполнил: студент группы 6231-010402D
Васильев Артём

Проверил: _____

Самара, 2026

Содержание

Введение . . . 3

1. Исходные данные и средства реализации . . . 3

1.1. Исходные данные . . . 3

1.2. Программные средства . . . 3

1.3. Структура программы . . . 3

2. Задание №1. Предобработка данных . . . 4

2.1. Алгоритм обработки . . . 4

2.2. Результаты . . . 4

3. Задание №2. Подсчёт частоты слов (WordCount) . . . 5

3.1. Алгоритм обработки . . . 5

3.2. Результаты . . . 5

4. Задание №3. Кластеризация текстовых данных . . . 6

4.1. Подготовка признаков . . . 6

4.2. Алгоритмы кластеризации . . . 7

4.3. Подбор числа кластеров . . . 7

4.4. Результаты кластеризации при k = 9 . . . 9

4.5. Визуализация . . . 9

4.6. Темы кластеров . . . 10

5. Возникшие проблемы и их решение . . . 11

Заключение . . . 11

Приложение А. Распределение постов по кластерам . . . 12

Приложение Б. Файлы результатов . . . 13

Введение

Цель работы: научиться подготавливать и обрабатывать данные, собранные из социальной сети, и познакомиться с задачей кластеризации текстовой информации.

В работе используются посты сообщества Самарского университета во «ВКонтакте» за август 2026 года, собранные в лабораторной работе №1. Повторное обращение к API социальной сети не требуется.

Задачи работы:

- выполнить предобработку данных: извлечь тексты постов и очистить их от мусора, ссылок и дубликатов (задание №1);
- реализовать подсчёт частоты слов с лемматизацией и удалением стоп-слов и сохранить результат в файл (задание №2);
- сгруппировать посты по тематическому сходству как минимум тремя алгоритмами, сравнить результаты, подобрать число кластеров и построить визуализацию (задание №3).

1. Исходные данные и средства реализации

1.1. Исходные данные

Таблица 1 – Характеристики исходного набора данных

Параметр	Значение
Источник	сообщество Самарского университета во «ВКонтакте»
Файл	lab1/results/samara_university_august_2026.csv
Период публикаций	2026-08-02 – 2026-08-31
Количество записей	40
Поля файла	id, date, text, likes, comments, reposts, views, link, attachments
Поле, используемое в работе	text

1.2. Программные средства

Работа выполнена на языке Python 3.12 в виртуальном окружении; полный список версий зафиксирован в файле req.txt. Основные библиотеки: pandas (загрузка и сохранение данных), emoji (удаление эмодзи), pymorphy3 (лемматизация), nltk (стоп-слова), scikit-learn (TF-IDF, кластеризация, PCA, метрики), matplotlib и seaborn (графики).

1.3. Структура программы

Решение разделено на модули в папке lab2. Запуск всей цепочки выполняется из корня проекта командой `python main.py`, которая вызывает функцию `run_lab2_pipeline`.

Таблица 2 – Модули лабораторной работы

Файл	Назначение
clean_text.py	загрузка данных и очистка текстов (задание №1)
word_frequency.py	лемматизация, удаление стоп-слов, частотный словарь (задание №2)
k_selection.py	опыт при разных k и выбор числа кластеров (задание №3)
text_clustering.py	TF-IDF, кластеризация тремя алгоритмами, визуализация (задание №3)
pipeline.py	последовательный запуск всех этапов

2. Задание №1. Предобработка данных

2.1. Алгоритм обработки

Функция `load_and_clean_posts` выполняет следующие шаги:

- загружает файл CSV или JSON в таблицу pandas и проверяет наличие столбца text;
- извлекает тексты в список, отбрасывая записи без текста;
- удаляет эмодзи с помощью библиотеки emoji;
- удаляет ссылки регулярным выражением;
- заменяет переносы строк и повторяющиеся пробелы одним пробелом;
- удаляет дубликаты, сохраняя исходный порядок постов.

```
text = emoji.replace_emoji(text, replace="")
text = re.sub(r"https?://\S+|www\.\S+", "", text, flags=re.MULTILINE)
text_cleaned = re.sub(r"\s+", " ", text).strip()
...
cleaned_texts = list(dict.fromkeys(cleaned_texts))  # удаление дубликатов
```

2.2. Результаты

Таблица 3 – Результаты предобработки

Показатель	Значение
Записей в исходном файле	40
Записей без текста	1
Найдено дубликатов	0
Постов после очистки	39
Длина поста, символов: средняя / минимальная / максимальная	1042 / 228 / 2627

Известное ограничение. Внутренние ссылки VK записаны в виде `[https://vk.ru/адрес|Текст ссылки]`. Регулярное выражение удаляет всё до первого пробела, поэтому вместе с адресом теряется первое слово подписи, а скобки остаются: например, остаётся «[центр]». Это затронуло 9 из 39 постов. На кластеризацию и частоты это влияет слабо, но в следующей версии такие ссылки стоит обрабатывать отдельно.

3. Задание №2. Подсчёт частоты слов (WordCount)

3.1. Алгоритм обработки

Обработка разделена на две функции: `lemmatize_texts` готовит леммы для каждого поста, а `analyze_word_frequrncy` считает частоты по всему корпусу. Те же леммы затем используются в кластеризации.

- **Токенизация.** Текст приводится к нижнему регистру, слова выделяются регулярным выражением `[а-яёа-z]+`. Числа и знаки препинания отбрасываются, как и слова из одной буквы.
- **Лемматизация.** Разные словоформы считаются одним словом: каждое слово приводится к начальной форме. Берётся наиболее вероятный разбор, предложенный морфологическим анализатором.
- **Стоп-слова.** Исключается стандартный русский список из nltk и дополнительный список: год, это, который, свой, весь, то, так, один, еще, уже.
- **Подсчёт и сохранение.** Частоты считаются с помощью Counter и сохраняются в CSV со столбцами word и frequency.

```
for word in words:
    if len(word) < 2: continue
    normal_form = morph.parse(word)[0].normal_form
    if normal_form in stop_words: continue
    lemmas.append(normal_form)
...
word_counts = Counter()
for text in lemmatized_texts:
    word_counts.update(text.split())
```

Выбор библиотеки. В задании предлагается PyMorphy2, однако версия 0.9.1 не запускается на Python 3.12: она использует удалённые модуль pkg_resources и функцию inspect.getargspec. Поэтому применён pymorphy3 — поддерживаемый форк PyMorphy2 с тем же программным интерфейсом и русским словарём OpenCorpora.

3.2. Результаты

После обработки в корпусе осталось 3752 вхождений и 1806 уникальных лемм. Из них 1129 лемм (62,5%) встречаются только один раз. Полный словарь сохранён в файле lab2/results/word_frequency.csv.

Таблица 4 – 20 самых частых лемм

№	Слово	Частота	№	Слово	Частота
1	университет	87	11	центр	16
2	самарский	47	12	развитие	15
3	студент	36	13	космический	15
4	наш	29	14	студенческий	15
5	проект	27	15	всё	15
6	программа	24	16	область	15
7	королёв	23	17	россия	14
8	новый	22	18	стать	14
9	институт	18	19	наука	14
10	регион	17	20	человек	14

Верхнюю часть словаря ожидаемо занимают слова, связанные с самим сообществом: «университет», «самарский», «студент», «королёв». Заметны также темы науки и космоса («проект», «программа», «наука», «космический») и региональная повестка («регион», «область»).

В словаре остались слова с малой смысловой нагрузкой, например «наш», «всё», «стать». Форма «всё» не приводится к лемме «весь» из списка стоп-слов и потому не отфильтровывается. Список стоп-слов можно расширить.

4. Задание №3. Кластеризация текстовых данных

4.1. Подготовка признаков

Каждый пост рассматривается как отдельный документ и представляется вектором TF-IDF, построенным по леммам без стоп-слов. Параметры заданы в функции `build_tfidf_vectorizer`.

Таблица 5 – Параметры TF-IDF

Параметр	Значение	Смысл
max_features	1000	ограничение числа признаков
min_df	2	слово должно встречаться минимум в двух документах
max_df	0,85	исключаются слова, встречающиеся более чем в 85% документов
ngram_range	(1, 2)	используются отдельные слова и пары слов

В результате получена матрица размером 39 × 654 (документы × признаки). Заполнено лишь 8,2% её ячеек: посты короткие, и общих слов у них мало. Это важно учитывать при оценке качества кластеризации.

4.2. Алгоритмы кластеризации

Использованы три алгоритма из модуля sklearn.cluster: KMeans (метод k-средних), MiniBatchKMeans (быстрая версия для больших данных) и AgglomerativeClustering (иерархическая кластеризация).

4.3. Подбор числа кластеров

Число кластеров подбиралось экспериментально при k от 2 до 15 для всех трёх алгоритмов. KMeans и MiniBatchKMeans запускались по 20 раз с разными начальными значениями, а значения метрик усреднялись. Агломеративная кластеризация детерминирована, поэтому для неё достаточно одного запуска. Рассчитывались:

- силуэтный коэффициент с косинусным расстоянием (чем выше, тем лучше);
- инерция KMeans для метода локтя;
- индекс Дэвиса–Болдина (чем ниже, тем лучше);
- размер наименьшего кластера;
- устойчивость — скорректированный индекс Рэнда (ARI) между разбиениями разных запусков.

Для сравнения KMeans запускался на тех же данных, в которых значения каждого признака перемешаны между документами. Такая базовая линия показывает, какой силуэт получается при отсутствии структуры.

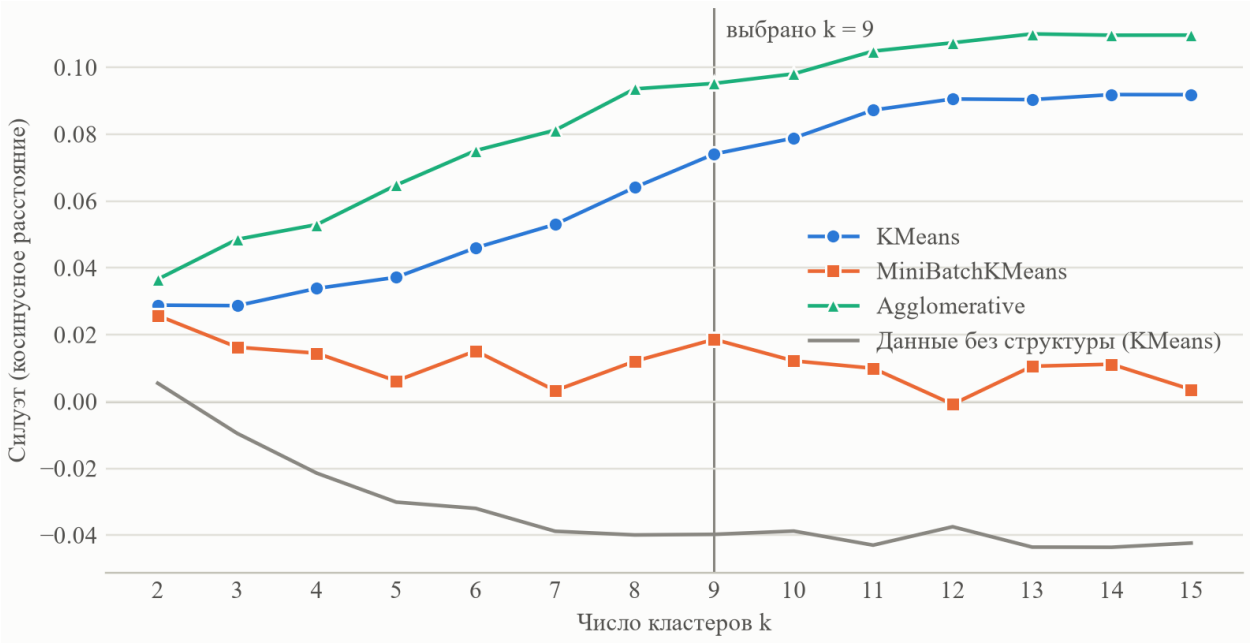


Рисунок 1 – Силуэтный коэффициент при разных k; вертикальная линия отмечает выбранное значение

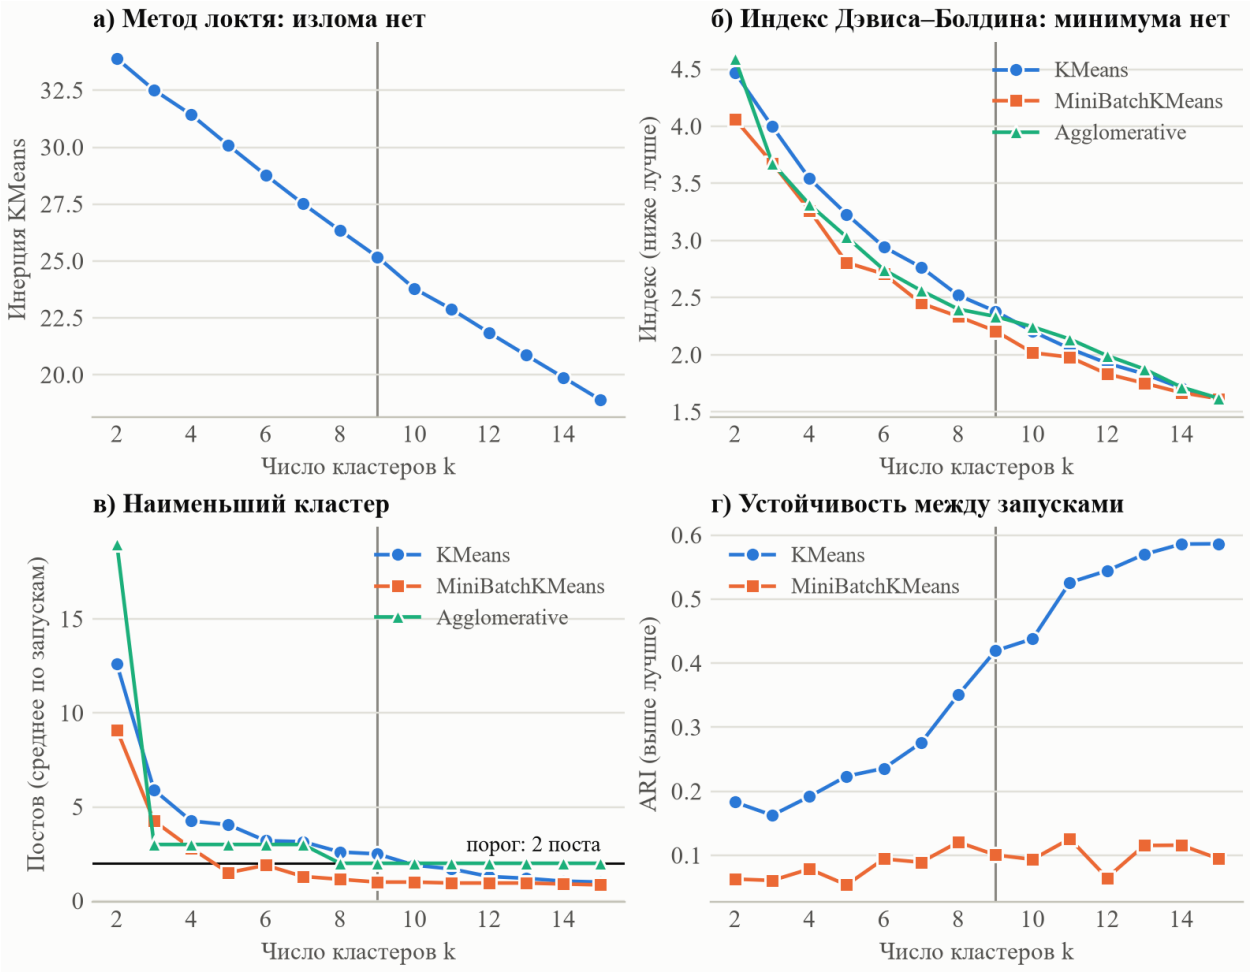


Рисунок 2 – Дополнительные метрики при разных k; вертикальная линия отмечает k = 9

Таблица 6 – Метрики при отдельных значениях k (средние по запускам)

k	Силуэт KMeans	Силуэт Agglomerative	Силуэт MiniBatchKMeans	Наименьший кластер KMeans	ARI KMeans
2	0,029	0,037	0,026	12,60	0,18
4	0,034	0,053	0,014	4,25	0,19
6	0,046	0,075	0,015	3,20	0,24
7	0,053	0,081	0,003	3,15	0,28
8	0,064	0,094	0,012	2,60	0,35
9	**0,074**	**0,095**	**0,019**	**2,50**	**0,42**
10	0,079	0,098	0,012	1,90	0,44
12	0,091	0,107	-0,001	1,30	0,54
14	0,092	0,110	0,011	1,05	0,59

По графикам видно, что явного оптимума нет. На кривой инерции нет излома, а индекс Дэвиса–Болдина монотонно снижается. Силуэт растёт примерно до k = 12–14, но этот рост частично объясняется дроблением данных: начиная с k = 10 у KMeans в части запусков появляются кластеры из одного поста, а к k = 15 они возникают практически всегда.

Поэтому было принято следующее **правило выбора**: максимальный средний силуэт KMeans при условии, что наименьший кластер в среднем содержит не менее двух постов. Этому правилу соответствует **k = 9**.

Выбор зависит от порога. При пороге в 3 поста получается k = 7, а без порога — k = 14–15. Значение k = 9 следует считать разумным компромиссом для малого набора из 39 постов, а не строгим оптимумом.

4.4. Результаты кластеризации при k = 9

Таблица 7 – Количество документов в кластерах

Кластер	KMeans	MiniBatchKMeans	Agglomerative
0	5	3	8
1	5	21	4
2	6	1	3
3	4	4	8
4	5	2	3
5	3	2	3
6	3	3	3
7	5	1	2
8	3	2	5
Силуэт итогового запуска	**0,060**	**0,011**	**0,095**

Номера кластеров разных алгоритмов не соответствуют друг другу. Распределение каждого поста по кластерам приведено в приложении А и сохранено в файле lab2/results/cluster_assignments.csv.

Сравнение алгоритмов. Наибольший силуэт показала агломеративная кластеризация. KMeans даёт самые равномерные кластеры размером от 3 до 6 постов. В итоговом запуске (random_state = 42) его силуэт равен 0,060, что ниже среднего по запускам значения 0,074. MiniBatchKMeans подошёл хуже всего: он поместил 21 из 39 постов в один кластер и неустойчив между запусками (ARI около 0,1). Это ожидаемо: алгоритм рассчитан на большие объёмы данных.

Абсолютные значения силуэта низкие, то есть кластеры сильно пересекаются. При этом они выше базовой линии (около −0,04), поэтому некоторая тематическая структура в данных есть.

4.5. Визуализация

Для наглядного представления размерность признакового пространства снижена до двух измерений методом PCA. Каждая точка соответствует посту, а кластер обозначен и цветом, и формой маркера.

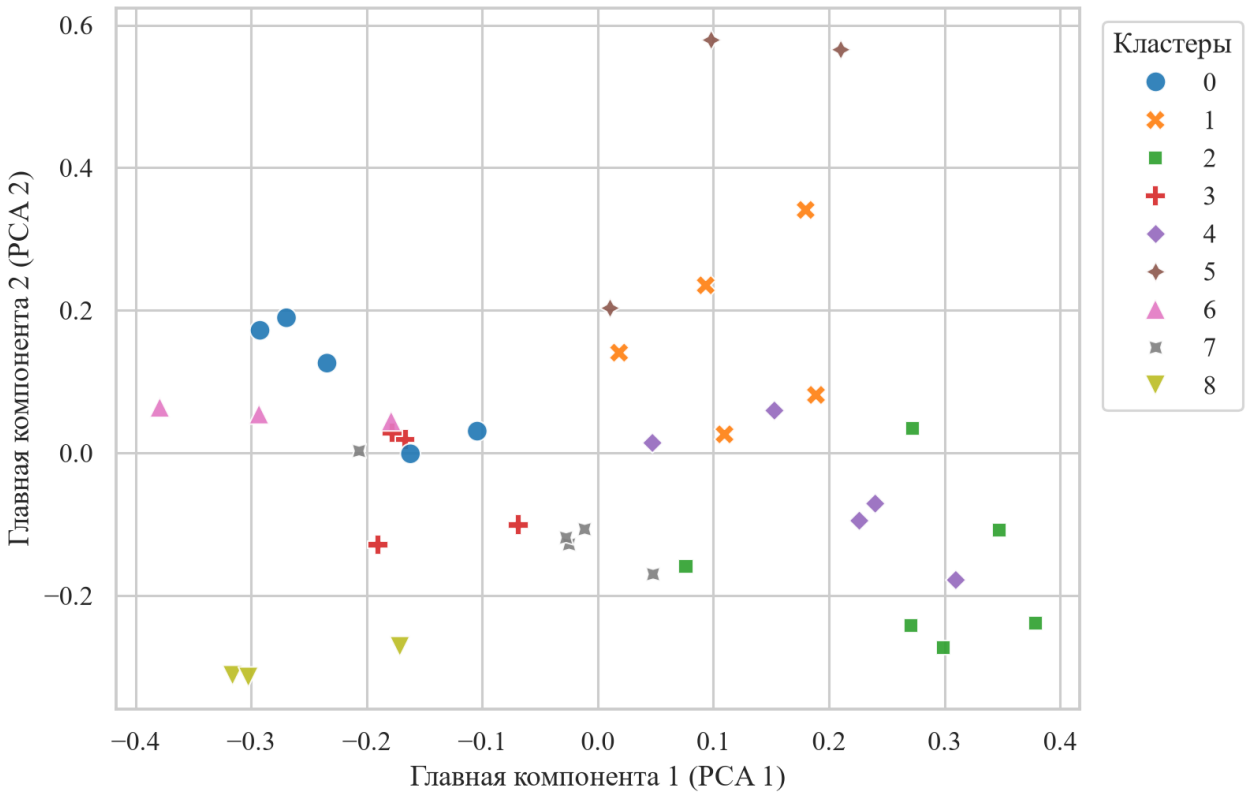


Рисунок 3 – Посты в пространстве двух главных компонент, кластеры KMeans при k = 9

Две компоненты объясняют только 9,6% дисперсии (5,0% и 4,6%). Поэтому график даёт лишь приближённое представление о структуре: посты, близкие на плоскости, не обязательно близки в исходном пространстве, и наоборот. Кластеризация выполнялась в исходном пространстве TF-IDF, а не на плоскости PCA.

4.6. Темы кластеров

Темы определены вручную по самым весомым словам кластера и по началу входящих в него постов, поэтому описание является интерпретацией. Оно приведено для кластеров KMeans.

Таблица 8 – Темы кластеров KMeans

№	Постов	Тема	Ключевые слова
0	5	Интервью и познавательные материалы: ценности, история, день флага	почему, кафедра, помогать, ценность, друг, наш
1	5	Достижения студентов: стипендии, конкурсы, награды	студент, андрей, дмитрий, разработка, экономика, стипендиат
2	6	Университет и наука: выступления ректора, программы, инфраструктура (смешанный кластер)	университет, программа, развитие, студенческий, самарский, участвовать
3	4	Рубрики о психологии и истории региона	история, мочь, рубрика, центр, каждый, регион
4	5	Приёмная кампания, выпускники и рейтинги (смешанный кластер)	самарский, участник, университет, выпускник, абитуриент, королёв

№	Постов	Тема	Ключевые слова
5	3	Первокурсники и начало учебного года	институт, факультет, первокурсник, студенческий жизнь, ждать, жизнь
6	3	Медиавыпуски: подкаст, программа, комикс о безопасности	выпуск, человек, страх, всё, технология, использовать технология
7	5	Команды и клубы: спорт, инженерные соревнования, туризм	команда, проект, клуб, август, всё, участие
8	3	Ботанический сад университета	сад, ботанический сад, ботанический, ботсад, сад самарский, открытие

Наиболее чётко выделяется кластер о ботаническом саде: эти же три поста образуют отдельный кластер и в агломеративной кластеризации. Кластеры 2 и 4 менее однородны и включают посты на разные темы.

5. Возникшие проблемы и их решение

Таблица 9 – Проблемы, выявленные в процессе работы

Проблема	Причина	Решение
Ошибка при создании MorphAnalyzer	PyMorphy2 0.9.1 несовместим с Python 3.12	переход на pymorphy3
В словарь попадал только первый пост (153 вхождения)	подсчёт и return находились внутри цикла по постам	подсчёт вынесен за цикл (3752 вхождения)
Ошибка при построении графика	скобка вызова pd.DataFrame перенесена на новую строку, опечатка в параметре palette	исправлен синтаксис и параметр
TF-IDF строился по сырому тексту	словоформы считались разными признаками	векторизация выполняется по леммам
Неочевидный выбор k	метрики не дают явного оптимума	опыт при k от 2 до 15 и явное правило выбора

Заключение

В ходе работы выполнены все три задания. Из 40 записей получено 39 очищенных постов. Построен частотный словарь из 1806 лемм, самые частые из которых — «университет», «самарский» и «студент».

Посты сгруппированы тремя алгоритмами при k = 9. Лучший силуэт показала агломеративная кластеризация, наиболее равномерные кластеры дал KMeans, а MiniBatchKMeans оказался неподходящим для такого малого набора данных. Часть кластеров имеет понятную тему, например ботанический сад.

Качество разделения невысокое: силуэт не превышает 0,11 ни при одном из проверенных k, а выбор k зависит от принятого порога. Основная причина, вероятно, в том, что постов мало, они короткие и посвящены одному университету. Для более устойчивых результатов стоит собрать данные за больший период, расширить список стоп-слов и исправить обработку внутренних ссылок VK.

Приложение А. Распределение постов по кластерам

В таблице приведено начало каждого поста. Полные тексты находятся в файле lab2/results/cluster_assignments.csv.

Таблица 10 – Номера кластеров по алгоритмам

№	Начало поста	KMeans	MiniBatch	Agglom.
1	"У научных коллективов университета много значимых…	2	1	8
2	От Центра управления полётами до скалодрома: участники…	2	1	8
3	Мнение эксперта: «Политическое лобби нашему авиапрому нужно и…	2	5	7
4	Чем может обернуться заманчивое предложение о легких деньгах?…	3	7	1
5	Один телефонный звонок может стать началом опасной цепочки…	6	3	0
6	«Самая ценная реликвия, которую мне передали родители и…	0	1	0
7	Приёмная кампания в Самарском национальном исследовательском…	4	1	3
8	День знаний Самарского университета им. Королёва Первого…	5	0	4
9	Футбольный дебют – и уже победа! В Самаре прошёл традиционный…	7	1	2
10	Подготовка инженеров для космоса сегодня невозможна без…	2	1	8
11	Студенты предложили свои варианты привлечения внимания…	7	2	2
12	Александр Борисович Фетисов: «Чтобы решить задачу, в неё…	7	5	7
13	Сегодня – День Государственного флага России…	0	3	0
14	Николай Бестужев – кто он? По мнению доктора филологических…	0	1	0
15	42 студента Самарского университета им. Королёва –…	1	4	6
16	История Самарской области – это не только события и даты. Это…	3	1	1
17	Продолжается прием заявок на участие в «Зимнем университете»…	2	6	8
18	19 августа в Самарской области – региональный День особо…	8	1	5
19	Архитектура Самары отражает богатое культурное и духовное…	3	1	1
20	Наш выпускник Кирилл Галанов назначен общественным помощником…	2	6	3
21	[центр] в рамках рубрики «Взгляд психолога» продолжает цикл…	3	1	1
22	Дмитрий Фомичев, студент Института авиационной и…	1	1	4
23	Два технических клуба, 8 команд, 5 призовых мест!…	7	1	2
24	Семь студентов и аспирантов университета стали победителями…	1	1	3

№	Начало поста	KMeans	MiniBatch	Agglom.
25	[центр] расспросил студенческих лидеров из четырех…	0	3	0
26	Магистр Института экономики и управления Андрей Королев стал…	1	1	6
27	Смотрите, кто пришел! Приемная кампания движется к финалу, и…	5	1	3
28	Добрый день, уважаемые слушатели! Сегодня мы представляем вам…	6	3	0
29	Приветствуем вас, дорогие первокурсники! Мы искренне рады…	5	0	4
30	В новом выпуске программы «Эксперименты Платоновой» ведущая…	6	8	0
31	В Самарской области объявили победителей ежегодного конкурса…	1	4	6
32	Это лето выдалось на редкость богатым на грозы, да еще и в…	0	8	0
33	Портрет первокурсника-2026 Смотрите, кто пришел на бюджет!…	4	1	3
34	В музеи, зоопарки и ботанические сады мы привыкли ходить,…	8	1	5
35	Самарская делегация приняла участие в работе международной…	4	0	3
36	Ольга Есипова удостоена Благодарности губернатора Самарской…	4	6	8
37	Завтра, 5 августа, в 15:00 закрывается окно возможности…	7	1	3
38	Выпускники химических направлений университета вошли в число…	4	1	3
39	Внимание! Открытие Ботанического сада Самарского университета…	8	1	5

Приложение Б. Файлы результатов

Таблица 11 – Файлы в папке lab2/results

Файл	Содержимое
word_frequency.csv	частотный словарь: слово и количество вхождений
k_selection_metrics.csv	метрики для каждого k и алгоритма
k_selection.png	графики метрик при разных k
cluster_assignments.csv	номер кластера каждого поста по всем алгоритмам
cluster_sizes.csv	количество документов в кластерах
cluster_top_terms.csv	самые весомые слова кластеров KMeans
clusters_visualization.png	точечный график кластеров KMeans в пространстве PCA